

Universidade de São Paulo
Instituto de Matemática e Estatística
Departamento de Matemática Aplicada

Gustavo Valencio Tofolo

Orientador: Prof. Dr. Francisco Felipe de Queiroz

**Ferramenta visual para exploração de estruturas
semiparamétricas em regressão**

São Paulo
2026

Sumário

1	Introdução	2
2	Atividades Desenvolvidas	2
3	Fundamentação Teórica	3
3.1	Curvas de Regressão	3
3.2	Regressão Linear Simples	4
3.2.1	Introdução	4
3.2.2	Suposições do modelo	4
3.2.3	Estimação de α e β	5
3.2.4	Estimação de σ^2	6
3.2.5	Coefficiente de determinação	6
3.3	Splines Polinomiais	7
3.3.1	Introdução	7
3.3.2	Intuição do modelo	7
3.3.3	B-splines	8
3.3.4	Estimação dos coeficientes	9
3.4	Splines Penalizados (P-splines)	10
3.5	Modelos Aditivos Estruturados	12
4	Metodologia	13
5	Desenvolvimento	15
6	Objetivos futuros e cronograma	21
7	Avaliação do Bolsista	21

1 Introdução

A análise de regressão é uma das principais ferramentas da estatística para investigar a relação entre variáveis. Em sua forma mais tradicional, essa relação é descrita por modelos paramétricos, como a regressão linear, nos quais se assume uma forma funcional específica para representar o comportamento médio da variável resposta em função das covariáveis. Embora esses modelos sejam amplamente utilizados, sua estrutura pode ser limitada quando os dados apresentam relações não lineares ou padrões mais complexos.

Nesse contexto, métodos de regressão não paramétrica e semiparamétrica oferecem maior flexibilidade ao permitir que a forma da função de regressão seja determinada a partir dos próprios dados. Entre essas abordagens, destacam-se os métodos baseados em splines, que constroem funções suaves por meio da combinação de polinômios definidos em diferentes intervalos do domínio da variável explicativa.

O presente projeto tem como objetivo desenvolver uma ferramenta computacional interativa para a visualização e a exploração de modelos de regressão, com ênfase em métodos não paramétricos baseados em splines e em seu uso pedagógico. Este relatório reúne a fundamentação teórica que sustenta esses modelos, da regressão linear simples aos splines penalizados, e a aplicação desenvolvida a partir dela. Nas seções seguintes, apresentam-se os fundamentos teóricos, a metodologia adotada, o desenvolvimento da ferramenta e os objetivos futuros do projeto.

2 Atividades Desenvolvidas

Consolidada a fundamentação teórica em etapas anteriores, o período considerado neste relatório concentrou-se no desenvolvimento da ferramenta computacional.

O trabalho partiu da revisão de um protótipo anterior, desenvolvido no início da graduação, que realizava apenas interpolação, isto é, curvas que passam exatamente pelos pontos. A análise desse protótipo permitiu identificar suas limitações e delimitar o que precisaria ser repensado na migração da interpolação para a regressão.

Em seguida, definiram-se os modelos a implementar (regressão linear simples, regressão polinomial, B-splines e P-splines) e a forma de organizá-los sob uma mesma formulação, a dos modelos aditivos estruturados. Os modelos foram implementados a partir de seus fundamentos, e não por meio de rotinas prontas, seguindo-se a seleção das funcionalidades expostas no painel de controle, como os controles de parâmetros e a visualização das bases. Foram também desenvolvidos os recursos de entrada e saída de dados, a importação de pontos por arquivo CSV e a geração de um relatório descritivo em PDF.

As implementações foram validadas por comparação com bibliotecas consolidadas, verificando-se a fidelidade dos ajustes obtidos. Houve participação regular nas reuniões do grupo de pesquisa vinculado ao orientador, no qual a ferramenta foi apresentada. As discussões e os retornos obtidos motivaram melhorias sucessivas. Por fim, redigiu-se o presente relatório.

3 Fundamentação Teórica

3.1 Curvas de Regressão

Para cada valor fixo da variável explicativa $X = x$, a variável resposta Y possui uma distribuição condicional, denotada por $f_{Y|X}(y | x)$.

Considere, por exemplo,

$$f_{Y|X}(y | x) = \frac{x + y}{4(2 + x)}, \quad 0 \leq x \leq 4, \quad 0 \leq y \leq 4.$$

Fixado $X = x_0$, a intersecção do plano $X = x_0$ com a superfície que representa $f_{Y|X}(y | x)$ define a função $f_{Y|X}(y | x_0)$. Se $x_0 = 2$, obtém-se

$$f_{Y|X}(y | 2) = \frac{2 + y}{16}, \quad 0 \leq y \leq 4.$$

Graficamente, tem-se:




Figura 1: Superfície da distribuição condicional exemplo e sua intersecção com o plano $X = x_0$.

A partir dessas seções verticais, pode-se calcular, para cada x_0 , o valor médio da variável resposta sob a densidade $f_{Y|X}(y | x_0)$. À medida que se refina a discretização de y , obtém-se o valor exato da esperança condicional.




Figura 2: Intersecções superfície-plano, valores médios de $\mathbb{E}[Y | X = x]$ e interpolação.

Motivados por essa construção intuitiva, definimos a esperança condicional de Y dado $X = x$

$$\mathbb{E}[Y | X = x] = \int_{-\infty}^{+\infty} y f_{Y|X}(y | x) dy.$$

A função

$$s(x) = \mathbb{E}[Y | X = x]$$

é denominada curva de regressão de Y sobre X [1].

3.2 Regressão Linear Simples

3.2.1 Introdução

A curva de regressão $s(x) = \mathbb{E}[Y \mid X = x]$ é um objeto populacional determinado pela distribuição conjunta de (X, Y) . Na prática, entretanto, a forma funcional de $s(x)$ é desconhecida, sendo observada apenas uma amostra de tamanho n de pares $(X_i, Y_i), i = 1, \dots, n$. Torna-se, portanto, necessário especificar uma classe de funções para aproximar $s(x)$ a partir dos dados.

A escolha mais simples consiste em assumir que a curva de regressão pertence à classe das funções lineares, isto é,

$$s(x) = \alpha + \beta x.$$

As observações individuais podem não coincidir exatamente com o comportamento médio descrito por $s(x)$, havendo uma componente aleatória associada ao fenômeno em estudo. De forma geral, pode-se decompor uma observação como

$$\text{observação} = \text{parte sistemática} + \text{parte aleatória}.$$

Para cada par (X_i, Y_i) , escreve-se então

$$Y_i = s(X_i) + \varepsilon_i = \alpha + \beta X_i + \varepsilon_i, \quad i = 1, \dots, n \quad (1)$$

onde ε_i representa o desvio em torno da média condicional, chamado usualmente de erro aleatório.

Obtém-se, dessa forma, o modelo de regressão linear simples, no qual a componente sistemática é descrita por uma reta, e a variabilidade remanescente é incorporada ao termo de erro.

3.2.2 Suposições do modelo

Para que os parâmetros α e β possam ser estimados, torna-se necessário estabelecer hipóteses adicionais sobre o comportamento do termo de erro ε_i e sobre a variável explicativa X .

Assume-se, inicialmente, que a variável explicativa é observada sem erro e tratada como dada no processo de estimação.

No que se refere ao termo de erro, supõe-se que este tenha média condicional nula, isto é,

$$\mathbb{E}[\varepsilon_i \mid X_i] = 0, \quad i = 1, \dots, n.$$

Essa condição implica que

$$\mathbb{E}[Y_i \mid X_i] = s(X_i),$$

isto é, que a função $s(x)$ coincide com a média condicional da variável resposta.

Adicionalmente, assume-se que

$$\text{Var}(\varepsilon_i \mid X_i) = \sigma^2, \quad i = 1, \dots, n,$$

isto é, que a variância do termo de erro seja constante ao longo dos valores de X .

Assume-se, ainda, que os erros são independentes entre si.

Tais hipóteses caracterizam o modelo linear clássico e serão adotadas ao longo desta seção. Extensões que relaxam essas condições, embora relevantes em diversos contextos, não serão consideradas no presente desenvolvimento.

3.2.3 Estimação de α e β

Considerando a amostra observada (x_i, y_i) , $i = 1, \dots, n$, o modelo (1) pode ser escrito como

$$y_i = \alpha + \beta x_i + \varepsilon_i.$$

De acordo com o princípio dos mínimos quadrados [2], estima-se α e β minimizando a soma dos quadrados dos resíduos, definidos por

$$\varepsilon_i^2 = [y_i - (\alpha + \beta x_i)]^2, \quad i = 1, \dots, n.$$

Define-se, então, a função objetivo

$$SQ(\alpha, \beta) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n [y_i - (\alpha + \beta x_i)]^2.$$

Denotamos por $(\hat{\alpha}, \hat{\beta})$ o par que minimiza $SQ(\alpha, \beta)$. Para encontrá-lo, resolve-se o sistema

$$\begin{cases} \frac{\partial SQ(\alpha, \beta)}{\partial \alpha} = 0 \\ \frac{\partial SQ(\alpha, \beta)}{\partial \beta} = 0. \end{cases}$$

Calculando as derivadas parciais e reorganizando os termos, chega-se ao sistema

$$\begin{cases} \sum_{i=1}^n y_i = n\alpha + \beta \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i y_i = \alpha \sum_{i=1}^n x_i + \beta \sum_{i=1}^n x_i^2. \end{cases}$$

Resolvendo-o, obtém-se

$$\begin{aligned} \hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ \hat{\alpha} &= \bar{y} - \hat{\beta} \bar{x}, \end{aligned}$$

onde $\bar{x}$ e $\bar{y}$ denotam as médias amostrais de x e y , respectivamente.

A função ajustada

$$\hat{s}(x) = \hat{\alpha} + \hat{\beta}x$$

constitui o estimador da curva de regressão $s(x)$.

Quanto à interpretação, o coeficiente angular $\hat{\beta}$ quantifica a variação média de Y associada a um incremento unitário em X , enquanto o intercepto $\hat{\alpha}$ corresponde ao valor médio estimado de Y quando $X = 0$, desde que tal ponto esteja no domínio observado.

Sob as hipóteses do modelo linear clássico, os estimadores de mínimos quadrados satisfazem

$$\mathbb{E}[\hat{\beta}] = \beta, \quad \mathbb{E}[\hat{\alpha}] = \alpha.$$

Além disso, possuem variâncias dadas por

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \text{Var}(\hat{\alpha}) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right).$$

3.2.4 Estimação de σ^2

Para cada observação, define-se o valor ajustado

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$$

e o resíduo correspondente

$$e_i = y_i - \hat{y}_i.$$

A soma dos quadrados dos resíduos é dada por

$$\text{SQRes} = \sum_{i=1}^n e_i^2.$$

Um estimador não-viesado da variância do termo de erro σ^2 é então

$$S_e^2 = \frac{\text{SQRes}}{n - 2}.$$

3.2.5 Coeficiente de determinação

O SQRes mensura as variações que permanecem nos dados após o ajuste do modelo, isto é, a parcela não explicada pela regressão. Define-se ainda

$$\text{SQReg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2,$$

que representa a variação explicada pelo modelo. A soma das variações pode então ser escrita como

$$\text{SQT} = \text{SQReg} + \text{SQRes}.$$

Define-se o coeficiente de determinação por

$$R^2 = \frac{\text{SQReg}}{\text{SQT}} = 1 - \frac{\text{SQRes}}{\text{SQT}},$$

o qual mede a proporção da variabilidade total de Y explicada pelo modelo ajustado.

3.3 Splines Polinomiais

3.3.1 Introdução

Recordando que o objeto de interesse é

$$s(x) = \mathbb{E}[Y \mid X = x],$$

observa-se que a regressão linear simples constitui apenas um caso particular das diversas suposições que podem ser feitas a respeito de $s(x)$, o que pode ser restritivo dependendo do fenômeno estudado. Essa motivação conduz ao estudo de modelos não paramétricos, nos quais se busca estimar $s(x)$ diretamente a partir dos dados, sem impor uma forma funcional específica, o que confere maior flexibilidade à modelagem.

Mantém-se, entretanto, a mesma estrutura básica considerada anteriormente para o termo de erro, isto é, considera-se o modelo

$$Y_i = s(X_i) + \varepsilon_i,$$

diferindo apenas na forma assumida para a curva de regressão.

Entre as diversas abordagens propostas na literatura para estimar essa função, destacam-se os métodos baseados em splines, que serão introduzidos a seguir [3].

3.3.2 Intuição do modelo

Considere inicialmente o modelo polinomial

$$s(x) = \gamma_0 + \gamma_1 x + \cdots + \gamma_l x^l,$$

no qual a curva de regressão é descrita por um polinômio de grau l . O aumento no número de parâmetros e a escolha do grau conferem maior flexibilidade quando comparado ao modelo linear simples. Ainda assim, polinômios globais frequentemente se mostram insuficientes para descrever relações mais complexas, podendo apresentar oscilações indesejáveis e dificuldade em capturar características locais da função, mesmo para graus elevados.

Uma alternativa consiste em dividir o domínio da variável explicativa em m intervalos e ajustar um polinômio em cada um deles por mínimos quadrados. Embora essa estratégia possa melhorar o ajuste, os polinômios obtidos em intervalos adjacentes não necessariamente coincidem nas extremidades, podendo gerar descontinuidades na função estimada.

Para evitar esse problema, impõem-se condições de suavidade nos limites dos intervalos, exigindo que os polinômios coincidam nesses pontos e que a função resultante seja $(l-1)$ vezes continuamente diferenciável. Funções obtidas dessa forma são chamadas de *splines polinomiais*.

A estimação depende da escolha do grau do polinômio e dos pontos que delimitam os intervalos, chamados de nós. Enquanto o grau controla a suavidade global da função, o número e a posição dos nós determinam a diversidade de formas que o modelo pode assumir.

Em termos de suavidade, é comum utilizar splines cúbicos. Quanto à disposição dos nós, uma escolha tradicional consiste em adotá-los igualmente espaçados. Se o domínio da variável explicativa for $[a, b]$, definem-se $m-1$ intervalos de largura

$$h = \frac{b-a}{m-1},$$

gerando nós

$$k_j = a + (j-1)h, \quad j = 1, \dots, m.$$

Alternativamente, os nós podem ser escolhidos a partir da inspeção do *scatter plot* dos dados, posicionando-os em regiões onde se observem mudanças mais acentuadas de curvatura.

Outro aspecto relevante é a quantidade de nós utilizada. Em geral, mais nós aumentam a flexibilidade da função estimada, enquanto menos nós impõem maior suavidade. Entretanto, um número excessivo de nós pode introduzir elevada variabilidade no ajuste e dificultar sua interpretação.

3.3.3 B-splines

Uma forma conveniente de representar splines polinomiais, dado o grau e a configuração dos nós, é por meio de B-splines. Para isso, introduz-se inicialmente o conceito de base de funções.

Uma base de funções consiste em um conjunto de funções previamente especificadas que permite representar outras funções por meio de combinações lineares. Assim, dada uma coleção $\phi_1(x), \dots, \phi_d(x)$, escreve-se

$$s(x) = \sum_{j=1}^d \gamma_j \phi_j(x),$$

onde γ_j são parâmetros a serem estimados.

No caso das splines polinomiais, busca-se uma base que preserve a estrutura de polinômios por partes e garanta suavidade nas junções dos intervalos definidos pelos nós. As chamadas B-splines fornecem exatamente uma base com essas propriedades.

Uma base de B-splines associada a m nós e grau l consiste em $d = (m + l - 1)$ funções polinomiais por partes de grau l , $(l - 1)$ vezes continuamente diferenciáveis. Cada função base possui suporte local, sendo positiva apenas no intervalo determinado por $(l + 2)$ nós consecutivos.

Define-se um B-spline de grau zero como

$$B_j^0(x) = I(k_j \leq x < k_{j+1}), \quad j = 1, \dots, d - 1.$$

A partir dessas funções base, B-splines de graus superiores são construídos de forma recursiva, combinando funções do grau imediatamente inferior para obter polinômios de maior grau enquanto se preserva a estrutura local da base.

Formalmente, para $l \geq 1$, define-se

$$B_j^l(x) = \frac{x - k_{j-l}}{k_j - k_{j-l}} B_{j-1}^{l-1}(x) + \frac{k_{j+1} - x}{k_{j+1} - k_{j+1-l}} B_j^{l-1}(x).$$

Para aplicar essa construção, é necessário estender a sequência de nós além do intervalo $[a, b]$, acrescentando l nós adicionais em cada extremidade. No caso de nós igualmente espaçados, utiliza-se o mesmo espaçamento para definir esses novos pontos. Caso contrário, podem-se adotar extensões baseadas nas distâncias observadas entre os nós existentes.

Veja a seguir um exemplo de base de B-splines para seis nós e graus $l = 0, 1, 2, 3$:




Figura 3: Bases de B-splines para seis nós igualmente espaçados no intervalo $[0, 1]$ e $l = 0, 1, 2, 3$.

3.3.4 Estimação dos coeficientes

Uma vez definida a base de B-splines, a estimação da função de regressão reduz-se à estimação dos coeficientes da combinação linear dessas funções. Substituindo a representação

$$s(x) = \sum_{j=1}^d \gamma_j B_j(x)$$

no modelo de regressão, obtém-se

$$Y_i = \sum_{j=1}^d \gamma_j B_j(X_i) + \varepsilon_i,$$

o que corresponde a um modelo linear nas funções base.

Dessa forma, dada a amostra, os coeficientes γ_j podem ser estimados por mínimos quadrados. Em notação matricial, definindo a matriz $\mathbf{B}$ cujos elementos são $B_j(x_i)$, o estimador é dado por

$$\hat{\gamma} = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}.$$

A função de regressão estimada é então

$$\hat{s}(x) = \sum_{j=1}^d \hat{\gamma}_j B_j(x).$$

A Figura abaixo ilustra essa decomposição. Na primeira linha apresentam-se as funções base de grau 3, juntamente com os dados simulados. Na segunda linha são mostradas as contribuições individuais $\hat{\gamma}_j B_j(x)$ após a estimação dos coeficientes. Por fim, a terceira linha apresenta a função resultante $\hat{s}(x) = \sum_{j=1}^d \hat{\gamma}_j B_j(x)$ obtida pela combinação linear dessas contribuições.




Figura 4: Bases de B-splines, contribuição por termo e combinação linear no ajuste ilustrativo.

3.4 Splines Penalizados (P-splines)

Como discutido anteriormente, o número de nós é uma variável determinante para a qualidade do ajuste. Para reduzir a dependência dessa escolha, introduz-se um termo de penalização durante a estimação, que atua controlando oscilações excessivas que podem surgir quando se utiliza um número relativamente elevado de nós.

Para tal, escolhe-se um número de nós próximo a 30 e realiza-se a estimação por mínimos quadrados penalizados. Uma forma bastante utilizada de penalização é baseada em diferenças finitas de ordem r entre coeficientes consecutivos γ_j .

Seja Δ^r o operador de diferença de ordem r . A diferença de primeira ordem é definida por

$$\Delta^1 \gamma_j = \gamma_j - \gamma_{j-1}.$$

Diferenças de ordem superior são obtidas recursivamente a partir da relação

$$\Delta^r \gamma_j = \Delta^{r-1} \gamma_j - \Delta^{r-1} \gamma_{j-1}.$$

Por exemplo,

$$\Delta^2 \gamma_j = (\gamma_j - \gamma_{j-1}) - (\gamma_{j-1} - \gamma_{j-2}).$$

A estimação é então obtida pela minimização da soma de quadrados penalizada

$$\text{PLS}(\lambda) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^d \gamma_j B_j(x_i) \right)^2 + \lambda \sum_{j=r+1}^d (\Delta^r \gamma_j)^2.$$

O primeiro termo mede o erro de ajuste aos dados, enquanto o segundo termo penaliza diferenças sucessivas entre coeficientes. O parâmetro $\lambda \geq 0$ controla o peso dessa penalização.

A ordem das diferenças determina o tipo de comportamento favorecido pelo modelo. Com diferenças de primeira ordem, penalizam-se variações entre coeficientes consecutivos, favorecendo sequências aproximadamente constantes. Com diferenças de segunda ordem, penalizam-se mudanças nessas variações, de modo que coeficientes que evoluem de forma aproximadamente linear recebem pouca penalização.

Quando λ assume valores suficientemente grandes, a penalização domina o processo de estimação e as diferenças de ordem r tendem a zero. Nessa situação, os coeficientes passam a se comportar aproximadamente como um polinômio de grau $r - 1$, e a função ajustada se aproxima de um polinômio desse mesmo grau. No caso de diferenças de segunda ordem, por exemplo, o ajuste tende a uma função aproximadamente linear.

Para realizar a estimação, é conveniente escrever a penalização em notação matricial. Seja

$$\boldsymbol{\gamma} = \begin{bmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_d \end{bmatrix}.$$

Para as diferenças de primeira ordem, pode-se escrever $\mathbf{D}_1 \boldsymbol{\gamma}$, onde

$$\mathbf{D}_1 = \begin{bmatrix} -1 & 1 & 0 & \cdots & 0 \\ 0 & -1 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & -1 & 1 \end{bmatrix}.$$

Para as diferenças de segunda ordem, tem-se

$$\mathbf{D}_2 = \begin{bmatrix} 1 & -2 & 1 & 0 & \cdots & 0 \\ 0 & 1 & -2 & 1 & \cdots & 0 \\ 0 & 0 & 1 & -2 & \ddots & 0 \\ \vdots & \vdots & \vdots & \ddots & \ddots & 1 \end{bmatrix}.$$

Diferenças de ordem maior podem ser obtidas recursivamente através de

$$\mathbf{D}_r = \mathbf{D}_1 \mathbf{D}_{r-1}.$$

O termo de penalização pode então ser escrito como

$$\lambda \sum_{j=r+1}^d (\Delta^r \gamma_j)^2,$$

ou, de forma equivalente,

$$\lambda \|\mathbf{D}_r \boldsymbol{\gamma}\|^2 = \lambda \boldsymbol{\gamma}^\top \mathbf{D}_r^\top \mathbf{D}_r \boldsymbol{\gamma} = \lambda \boldsymbol{\gamma}^\top \mathbf{K}_r \boldsymbol{\gamma},$$

onde $\mathbf{K}_r = \mathbf{D}_r^\top \mathbf{D}_r$ é a matriz de penalização.

Em geral, os mínimos quadrados penalizados são escritos como

$$\text{PLS}(\lambda) = (\mathbf{y} - \mathbf{B}\boldsymbol{\gamma})^\top (\mathbf{y} - \mathbf{B}\boldsymbol{\gamma}) + \lambda \boldsymbol{\gamma}^\top \mathbf{K}_r \boldsymbol{\gamma},$$

onde $\mathbf{y}$ é o vetor das respostas observadas e $\mathbf{B}$ é a matriz das funções base avaliada nos pontos x_i .

Expandindo o primeiro termo, obtemos

$$\text{PLS}(\lambda) = \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{B}\boldsymbol{\gamma} - \boldsymbol{\gamma}^\top \mathbf{B}^\top \mathbf{y} + \boldsymbol{\gamma}^\top \mathbf{B}^\top \mathbf{B}\boldsymbol{\gamma} + \lambda \boldsymbol{\gamma}^\top \mathbf{K}_r \boldsymbol{\gamma}.$$

Derivando em relação a $\boldsymbol{\gamma}$ e igualando a zero, obtém-se

$$-2\mathbf{B}^\top \mathbf{y} + 2(\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K}_r) \boldsymbol{\gamma} = 0.$$

Logo,

$$(\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K}_r) \boldsymbol{\gamma} = \mathbf{B}^\top \mathbf{y}.$$

Assim, o estimador de mínimos quadrados penalizados é dado por

$$\hat{\boldsymbol{\gamma}} = (\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K}_r)^{-1} \mathbf{B}^\top \mathbf{y}.$$

Os modelos apresentados até aqui podem ser interpretados como casos particulares de uma classe mais ampla de modelos de regressão flexível. Essa perspectiva permite organizar diferentes especificações sob um mesmo arcabouço teórico, o que é particularmente conveniente do ponto de vista computacional. A formulação geral desse tipo de modelo será apresentada na seção seguinte.

3.5 Modelos Aditivos Estruturados

Os modelos discutidos nas seções anteriores podem ser formalizados como casos particulares dos chamados modelos aditivos estruturados. Nesse contexto, a função de regressão é representada como

$$s(\mathbf{x}) = \beta_0 + \sum_{j=1}^p f_j(\mathbf{x}),$$

onde cada função f_j descreve um componente associado às variáveis explicativas.

No caso considerado até aqui, tem-se $\mathbf{x} \in \mathbb{R}$ e $p = 1$, isto é, há apenas uma variável explicativa e um único componente funcional. Ainda assim, essa formulação fornece um ponto de partida conveniente para estender os modelos apresentados a situações mais gerais. Logo

$$s(x) = \beta_0 + f(x),$$

onde a função f descreve o efeito da variável explicativa sobre a variável resposta.

Diversos modelos estudados anteriormente podem ser interpretados como casos particulares dessa formulação. Por exemplo:

- efeitos lineares: $f(x) = \beta x$;
- efeitos polinomiais: $f(x) = \gamma_1 x + \dots + \gamma_l x^l$, onde l é o grau do polinômio;
- efeitos não paramétricos suaves: $f(x) = \sum_j \gamma_j B_j(x)$.

Para representar os diferentes tipos de efeito, resgata-se o conceito de base de funções. Assim, cada componente pode ser expresso como uma combinação linear de funções previamente especificadas. No caso geral, escreve-se

$$f(x) = \sum_{j=1}^d \gamma_j \phi_j(x),$$

onde ϕ_j são funções base e γ_j são coeficientes desconhecidos.

Substituindo essa representação no modelo de regressão, obtém-se

$$Y_i = \beta_0 + \sum_{j=1}^d \gamma_j \phi_j(X_i) + \varepsilon_i,$$

o que transforma o modelo em linear nos parâmetros.

Em notação matricial, definindo a matriz $\mathbf{B}$ cujos elementos são $\phi_j(x_i)$, o modelo pode ser escrito como

$$\mathbf{y} = \mathbf{B}\boldsymbol{\gamma} + \boldsymbol{\varepsilon}.$$

A estimação dos coeficientes pode então ser realizada por mínimos quadrados penalizados. Nesse caso, minimiza-se

$$(\mathbf{y} - \mathbf{B}\boldsymbol{\gamma})^\top (\mathbf{y} - \mathbf{B}\boldsymbol{\gamma}) + \lambda \boldsymbol{\gamma}^\top \mathbf{K} \boldsymbol{\gamma},$$

onde $\mathbf{K}$ é a matriz de penalização associada ao tipo de efeito considerado. No caso em que nenhuma penalização é desejada, toma-se simplesmente $\mathbf{K} = \mathbf{0}$, recuperando-se o estimador clássico de mínimos quadrados.

Derivando em relação a $\boldsymbol{\gamma}$ e igualando a zero, obtém-se

$$(\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K}) \boldsymbol{\gamma} = \mathbf{B}^\top \mathbf{y}.$$

Assim, o estimador assume a forma

$$\hat{\boldsymbol{\gamma}} = (\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K})^{-1} \mathbf{B}^\top \mathbf{y}.$$

Observa-se que essa expressão coincide com a obtida anteriormente para o caso das splines penalizadas, diferindo apenas na forma específica das matrizes $\mathbf{B}$ e $\mathbf{K}$.

4 Metodologia

A metodologia combinou revisão da literatura com desenvolvimento computacional. A partir dos fundamentos estudados, selecionaram-se os elementos que mais se beneficiam de visualização interativa. Em seguida, implementou-se a aplicação, e os modelos foram validados contra bibliotecas já consolidadas. A seguir, são detalhados o ferramental, a natureza dos dados, a abordagem de implementação e a validação.

Quanto ao ferramental, adotou-se a linguagem Python para o desenvolvimento, pela ampla adoção em ciência de dados e análise estatística, pela sintaxe acessível e pelo ecossistema científico consolidado. As operações numéricas, em especial a álgebra linear envolvida na estimação dos coeficientes, foram apoiadas pela biblioteca NumPy, enquanto a biblioteca SciPy foi empregada como referência na validação das implementações.

A interface interativa foi construída com a biblioteca PyGame, um motor gráfico leve e de código aberto que oferece controle direto sobre o desenho em tela e sobre o ciclo de eventos. Diferentemente de bibliotecas de plotagem estática, que produzem gráficos não interativos, o PyGame mostrou-se adequado à construção de um painel dinâmico que responde em tempo real às ações do usuário. Essa interatividade constitui o objetivo pedagógico central da ferramenta.

Para a geração de relatórios descritivos em PDF utilizou-se a biblioteca matplotlib, e os diálogos de seleção de arquivos (importação de dados e salvamento de relatórios) foram providos pelo módulo tkinter, ambos de uso corrente no ecossistema Python.

No que diz respeito aos dados de entrada, é importante mencionar que, por se tratar de uma ferramenta de exploração e ensino, os dados não provêm de um conjunto fixo, mas sim do próprio usuário. Há duas formas de entrada: na primeira, o usuário insere e manipula os pontos diretamente sobre a tela (adicionando, arrastando ou removendo observações), o que permite construir configurações arbitrárias de (x, y) e observar seus efeitos sobre o ajuste, enquanto na segunda, os dados são importados de um arquivo CSV com duas colunas, correspondentes às coordenadas x e y de cada observação.

Como a aplicação opera em coordenadas de tela (em pixels), e os dados importados podem estar em escalas que extrapolam a resolução da tela, por exemplo, é necessário reescaloná-los para que caibam na área de visualização. Aplica-se, para isso, uma transformação linear independente em cada eixo, que mapeia o intervalo observado dos dados para a região útil da tela, respeitando uma margem. O eixo vertical é invertido, uma vez que a convenção cartesiana (y crescente para cima) difere da convenção de tela (y crescente para baixo). Por ser aplicada a cada eixo separadamente, a transformação preserva a forma da relação entre as variáveis, ainda que altere suas escalas, o que é suficiente para os fins de visualização e de ajuste.

A implementação dos modelos foi conduzida sem recorrer a rotinas prontas de bibliotecas de modelagem, por duas razões principais. A primeira é a unificação: implementados sob a formulação de modelos aditivos estruturados (Seção 3.5), todos os modelos compartilham um mesmo estimador, $\hat{\gamma} = (\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{K})^{-1} \mathbf{B}^\top \mathbf{y}$, diferindo apenas na base $\mathbf{B}$ e na penalização $\mathbf{K}$. Bibliotecas usuais tratam cada modelo por uma rotina e uma interface próprias. Reuni-los sob um único arcabouço evidencia as relações entre eles e, sobretudo, dá acesso direto às matrizes de base e aos coeficientes estimados. É esse acesso que permite exibir, no caso dos splines, as funções base e suas contribuições individuais $\hat{\gamma}_j B_j$, informação que um ajuste pré-empacotado não expõe. A segunda razão é a extensibilidade: por não depender de rotinas externas, a lógica dos modelos permanece inteiramente acessível e a inclusão de novos modelos é simples, o que motiva a intenção de disponibilizar a ferramenta como software livre e de código aberto em um futuro próximo.

Para isso, adotou-se programação orientada a objetos. Uma classe abstrata (a classe-mãe) concentra o que é comum a todos os modelos, isto é, a montagem de $\mathbf{B}$ e $\mathbf{K}$ e a resolução das equações normais que fornecem $\hat{\gamma}$, e adota, por padrão, penalização nula ($\mathbf{K} = \mathbf{0}$). Cada modelo concreto é uma subclasse que herda essa lógica e especifica apenas a sua individualidade. A regressão linear

simples usa a base $[1, x]$, sem penalização. A regressão polinomial usa a base $[1, x, \dots, x^l]$, também sem penalização. O modelo de B-splines constrói a base pela recursão apresentada na Seção 3.3.3, sobre nós igualmente espaçados. O de P-splines reaproveita essa mesma base, acrescentando a penalização $\mathbf{K} = \mathbf{D}_r^\top \mathbf{D}_r$.

Tem-se então que a arquitetura traduz diretamente a afirmação de que os modelos diferem apenas por $\mathbf{B}$ e $\mathbf{K}$, e faz com que incluir um novo suavizador se reduza a definir uma nova subclasse com a sua base e, caso exista, a sua penalização.

Por fim, a correção das implementações foi verificada por batimento com bibliotecas consolidadas. Os ajustes da regressão linear simples e da regressão polinomial foram confrontados com os produzidos pela função de ajuste polinomial do NumPy, e os dos modelos de B-splines e P-splines, com a construção de B-splines da biblioteca SciPy. Em todos os casos, as diferenças observadas situaram-se na ordem da precisão numérica de máquina, inferiores a 10^{-13} , o que indica que a construção a partir dos fundamentos reproduz fielmente os métodos de referência.

5 Desenvolvimento

A aplicação inicia com uma área de visualização vazia, sobre a qual o usuário constrói e explora os modelos. A Figura 5 apresenta uma configuração típica: uma nuvem de pontos e, ajustadas a ela, as curvas dos modelos ativos, cada uma com uma cor associada e identificada na legenda. Os ajustes são recalculados continuamente, de modo que qualquer alteração nos dados se reflete de imediato nas curvas.




Figura 5: Uma nuvem de pontos e as curvas dos modelos ativos, identificadas na legenda.

A Figura 6 ilustra o efeito de modificar um único ponto. Em vermelho, destaca-se o terceiro ponto, da esquerda para a direita, deslocado em relação à Figura 5. Ainda que a alteração seja pontual, a configuração dos splines muda de forma expressiva, assumindo um traçado bastante distinto do anterior.




Figura 6: Reajuste em tempo real. A partir da configuração da Figura 5.

Vê-se que, ao arrastar as coordenadas e manipular deliberadamente o conjunto, o usuário acompanha esse movimento de forma contínua, o que confere à ferramenta um potencial lúdico, exploratório e de compreensão dos modelos.

Quanto à inserção dos dados, um clique com o botão esquerdo em uma área vazia adiciona um ponto. Para reposicioná-lo, basta arrastá-lo, também com o botão esquerdo. Já um clique com o botão direito sobre um ponto o remove. Um botão dedicado limpa todos os pontos de uma vez, permitindo recomeçar com um novo conjunto. Há ainda um botão de importação, que abre um seletor de arquivo para carregar um CSV com duas colunas, correspondentes a x e y . A Tabela 1 traz um exemplo (uma reta com um único ponto deslocado) e a Figura 7 mostra o resultado após a importação, já com os valores reescalados, conforme descrito na Seção 4.

Tabela 1: Uma reta ($y = 2x + 1$) com um único ponto deslocado, em $x = 4$.

x	0	1	2	3	4	5	6	7
y	1	3	5	7	18	11	13	15




Figura 7: Nuvem obtida após a importação do CSV da Tabela 1.

Os parâmetros de cada modelo são ajustados por um painel de controle, acessível por um botão no canto da tela. O painel organiza-se em abas, uma por modelo, e cada aba reúne os controles do modelo correspondente. Os intervalos oferecidos para cada parâmetro foram definidos de modo a cobrir os casos de interesse pedagógico, podendo ser ampliados sem alteração da lógica subjacente. Nas figuras a seguir, o painel de controle, à esquerda, é apresentado ao lado do ajuste resultante.

A regressão linear simples não possui parâmetros próprios de forma, de modo que seus únicos controles são os comuns a todos os modelos, a ativação e o recorte do domínio, não lhe correspondendo, portanto, uma figura de parâmetros.

No modelo polinomial, um controle deslizante define o grau do polinômio. A Figura 8 ilustra o efeito: com grau 1 obtém-se uma reta e, à medida que o grau aumenta, a curva ganha flexibilidade, passando a acompanhar a curvatura dos dados. O grau é limitado a valores baixos, uma vez que polinômios globais de grau elevado tendem a oscilar de forma indesejada.




Figura 8: Efeito do grau no modelo polinomial.

No modelo de B-splines, dois controles atuam sobre a base: o grau das funções e o número de nós. A Figura 9 reúne quatro configurações. Grau e número de nós baixos produzem curvas mais rígidas, ao passo que valores altos aumentam a flexibilidade, a ponto de, com muitos nós, o ajuste acompanhar até o ruído dos dados. O grau é mantido até três, valor usual para splines, correspondente ao spline cúbico.




Figura 9: Quatro configurações do B-spline, variando o grau e o número de nós.

O modelo de P-splines acrescenta aos controles o peso da penalização α e a ordem da diferença r . A Figura 10 reúne quatro configurações distintas. A ideia é empregar muitos nós e deixar α controlar a suavidade: com $\alpha = 0$ recupera-se o B-spline, que pode sobreajustar, e valores maiores de α suavizam progressivamente o ajuste. O controle de α usa uma escala discreta em potências de dez, pois seu efeito se dá em ordens de grandeza, e uma escala linear ocultaria a transição.




Figura 10: Quatro configurações do P-spline, variando também a penalização α e a ordem r .

Além de exibir o ajuste, é possível visualizar a própria construção dos modelos baseados em splines. A curva ajustada é uma combinação linear de funções base, $\hat{s}(x) = \sum_j \hat{\gamma}_j B_j(x)$, e duas opções tornam essa decomposição visível. A primeira exibe as próprias funções base B_j , e a segunda, as contribuições $\hat{\gamma}_j B_j$, isto é, cada base ponderada por seu coeficiente estimado, cuja soma reconstrói a curva final. Trata-se da mesma decomposição ilustrada na Figura 4, mas de forma interativa.

A Figura 11 mostra as duas opções ativas simultaneamente.




Figura 11: Visualização das funções base B_j e das contribuições $\hat{\gamma}_j B_j$ de um B-spline.

A ferramenta também gera, por um botão de exportação, um relatório em PDF que documenta a simulação. Nele constam um gráfico da configuração e, para cada modelo, sua equação, seus parâmetros, os coeficientes estimados e o coeficiente de determinação R^2 . Cabe uma ressalva sobre esse último: como modelos mais flexíveis tendem a apresentar R^2 mais alto, ainda que sobreajustem os dados, ele não deve ser tomado como critério de melhor modelo. Sua presença ilustra apenas o tipo de métrica que pode compor a saída, e outras medidas podem ser incorporadas com alterações simples no código.

Por fim, a correção das implementações foi verificada confrontando os ajustes da ferramenta com os de bibliotecas consolidadas. A Tabela 2 resume as diferenças máximas encontradas, todas na ordem da precisão numérica de máquina, o que indica que a construção a partir dos fundamentos reproduz fielmente os métodos de referência.

Tabela 2: Diferença máxima entre os modelos implementados e as referências consolidadas.

Implementação	Referência	Diferença máxima
RLS	<code>numpy.polyfit</code>	$1,7 \times 10^{-16}$
Polinomial	<code>numpy.polyfit</code>	$1,3 \times 10^{-13}$
B-spline (base)	<code>scipy.interpolate.BSpline</code>	$2,2 \times 10^{-16}$
B-spline (ajuste)	<code>scipy.interpolate.make_lsq_spline</code>	$6,8 \times 10^{-15}$
P-spline (ajuste)	base do <code>scipy</code> com penalização	$5,6 \times 10^{-16}$

Em conjunto, esses recursos fazem da ferramenta um ambiente interativo para explorar, de forma tangível, os modelos discutidos na fundamentação teórica, alinhado ao propósito pedagógico do projeto. A arquitetura modular, por sua vez, deixa em aberto caminhos naturais de extensão, discutidos na seção seguinte.

6 Objetivos futuros e cronograma

Com a fundamentação teórica consolidada e a ferramenta já em estado funcional, a etapa seguinte do projeto volta-se ao seu refinamento, à sua generalização e à sua aplicação. No que diz respeito à ferramenta, pretende-se aprimorar a interface, com uma janela redimensionável, um painel de controle em janela independente e a exibição de eixos nas coordenadas dos dados, além de incorporar novos recursos de análise, como diagnósticos da regressão linear. No que diz respeito aos modelos, pretende-se generalizar a estimação para mais de um componente funcional e estudar a extensão à suavização espacial, com base nas Seções 8.2 e 8.3 de Fahrmeir [3]. Pretende-se, ainda, aplicar a ferramenta a conjuntos de dados reais e disponibilizá-la como software livre, sob licença MIT. Por fim, será realizada uma avaliação preliminar de como a ferramenta poderia ser empregada como recurso pedagógico junto a estudantes, sem que seu uso efetivo constitua um compromisso desta etapa. O cronograma previsto para essas atividades é apresentado na Tabela 3.

Tabela 3: Cronograma de realização da etapa seguinte do projeto.

Atividades	Mês					
	1	2	3	4	5	6
Refinamento da interface e usabilidade						
Novos recursos de análise (diagnósticos e métricas)						
Generalização dos modelos ($p > 1$ e suavização espacial)						
Aplicação a conjuntos de dados reais						
Disponibilização em código aberto e avaliação preliminar de uso						
Redação da monografia final						

7 Avaliação do Bolsista

A participação no Programa Unificado de Bolsas (PUB) mostrou-se bastante positiva para o desenvolvimento deste projeto. O apoio concedido possibilitou dedicar mais tempo às atividades de estudo e pesquisa, contribuindo para o aprofundamento dos conhecimentos computacionais e para o amadurecimento da proposta do trabalho. Além disso, o programa incentivou a integração com o grupo de pesquisa e o contato com alunos de pós-graduação, o que proporcionou um ambiente acadêmico estimulante e favorável à troca de experiências. De forma geral, a bolsa representou um importante apoio para a continuidade e o desenvolvimento das atividades de iniciação científica.

Referências

- [1] Bussab, W. O.; Morettin, P. A. *Estatística Básica*, 6^a ed.; Saraiva: 2009.
- [2] Paula, G. A. *Regressão Linear Múltipla*; IME-USP: 2023.
- [3] Fahrmeir, L.; Kneib, T.; Lang, S.; Marx, B. *Regression: Models, Methods and Applications*; Springer: 2013.